

Analisis Prediksi *Customer Churn* dan Segmentasi Pelanggan sebagai Pendukung Strategi Retensi Pelanggan Menggunakan XGBoost dan K-Means: JINACS (Journal of Informatics and Computer Science)

Sierren Yorensa

24051214173@mhs.ac.id

Sistem Informasi, Fakultas Teknik, Universitas Negeri Surabaya

Abstrak— *Customer Churn* merupakan kondisi ketika pelanggan berhenti menggunakan layanan suatu perusahaan. Pada industri telekomunikasi, tingginya tingkat *Churn* dapat menyebabkan penurunan pendapatan serta meningkatnya biaya untuk memperoleh pelanggan baru. Oleh karena itu, diperlukan suatu pendekatan yang mampu mengidentifikasi pelanggan yang berpotensi melakukan *Churn* sehingga perusahaan dapat menyusun strategi retensi yang lebih efektif. Penelitian ini bertujuan untuk melakukan prediksi *customer Churn* dan segmentasi pelanggan menggunakan dataset Telco *Customer Churn* yang terdiri dari 7.043 data pelanggan. Metodologi yang digunakan mengacu pada CRISP-DM yang meliputi tahapan *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation*, dan *deployment*. Pada tahap klasifikasi digunakan algoritma XGBoost untuk memprediksi status *Churn* pelanggan. Untuk mengatasi ketidakseimbangan data digunakan metode SMOTE pada data latih. Selain itu, dilakukan segmentasi pelanggan menggunakan algoritma K-Means *Clustering* untuk mengelompokkan pelanggan berdasarkan karakteristik yang dimiliki. Hasil penelitian menunjukkan bahwa model XGBoost menghasilkan nilai *Accuracy* sebesar 76,65%, *Precision* sebesar 55,27%, *Recall* sebesar 63,10%, dan ROC-AUC sebesar 82,56%. Sementara itu, K-Means menghasilkan tiga *cluster* pelanggan dengan nilai *Silhouette Score* sebesar 0,2193. Hasil penelitian kemudian diimplementasikan dalam aplikasi web berbasis Streamlit untuk memudahkan visualisasi dan penggunaan model. Penelitian ini menunjukkan bahwa kombinasi XGBoost dan K-Means mampu membantu perusahaan dalam mengidentifikasi pelanggan yang berpotensi *Churn* serta mendukung penyusunan strategi retensi pelanggan yang lebih tepat sasaran.

Kata Kunci— *Customer Churn*, Data Mining, XGBoost, K-Means *Clustering*, SMOTE, Streamlit.

I. PENDAHULUAN

Industri telekomunikasi merupakan salah satu sektor yang memiliki tingkat persaingan yang sangat tinggi. Berbagai perusahaan telekomunikasi terus berupaya meningkatkan kualitas layanan, menawarkan paket yang lebih kompetitif, serta memberikan berbagai program promosi untuk mempertahankan pelanggan. Dalam kondisi tersebut,

keberhasilan perusahaan tidak hanya ditentukan oleh kemampuan memperoleh pelanggan baru, tetapi juga oleh kemampuan mempertahankan pelanggan yang sudah ada. Salah satu permasalahan yang sering dihadapi perusahaan telekomunikasi adalah *customer Churn*. *Churn* adalah cara para pelanggan memutuskan untuk pindah dari satu perusahaan ke perusahaan yang lain karena ada penawaran yang lebih menarik. Fenomena *Churn* ini tentu saja merugikan, karena mengurangi keuntungan atau pendapatan perusahaan [1].

Strategi retensi pelanggan menjadi aspek penting dalam menjaga keberlangsungan bisnis perusahaan telekomunikasi. Mempertahankan pelanggan yang ada menjadi isu yang signifikan dan merupakan salah satu tantangan utama yang dihadapi oleh banyak perusahaan. Seperti yang dikemukakan oleh Emmett C. Murphy dan Mark A. Murphy, pendapat pelanggan baru jauh lebih sulit daripada menjaga pelanggan yang sudah ada [2], serta biaya yang dikeluarkan perusahaan 5 kali lipat lebih banyak dibandingkan dengan memuaskan dan mempertahankan pelanggan lama [3]. Oleh karena itu, perusahaan perlu memahami karakteristik pelanggan dan mengidentifikasi pelanggan yang memiliki potensi untuk berhenti menggunakan layanan sejak dini. Dengan mengetahui pelanggan yang berisiko *Churn*, perusahaan dapat mengambil langkah preventif seperti pemberian promosi khusus, peningkatan kualitas layanan, maupun program loyalitas pelanggan yang lebih tepat sasaran.

Perkembangan teknologi informasi dan meningkatnya ketersediaan data pelanggan memberikan peluang bagi perusahaan untuk memanfaatkan teknik *data mining* dalam mendukung pengambilan keputusan. *Data mining* memungkinkan proses penggalian informasi dan pola tersembunyi dari data historis pelanggan sehingga dapat digunakan untuk memprediksi perilaku pelanggan di masa mendatang. Salah satu penerapan yang banyak dilakukan adalah prediksi *customer Churn* menggunakan algoritma *machine learning*. Melalui model prediksi yang tepat, perusahaan dapat mengetahui kemungkinan seorang pelanggan melakukan *Churn* berdasarkan berbagai atribut seperti lama berlangganan, biaya layanan, jenis kontrak, dan karakteristik penggunaan layanan lainnya.

Selain melakukan prediksi *Churn*, perusahaan juga perlu memahami karakteristik kelompok pelanggan yang dimiliki. Setiap pelanggan memiliki perilaku dan kebutuhan yang berbeda sehingga strategi retensi yang diterapkan tidak dapat

disamakan untuk seluruh pelanggan. Oleh karena itu, segmentasi pelanggan menjadi langkah penting untuk mengelompokkan pelanggan berdasarkan karakteristik tertentu. Hasil segmentasi dapat membantu perusahaan memahami profil setiap kelompok pelanggan dan menyusun strategi pemasaran maupun retensi yang lebih efektif sesuai dengan karakteristik masing-masing segmen.

Penelitian ini menggunakan metode XGBoost untuk melakukan prediksi *customer Churn* dan metode K-Means *Clustering* untuk melakukan segmentasi pelanggan pada dataset Telco Customer Churn. XGBoost dipilih karena memiliki kemampuan yang baik dalam menangani permasalahan klasifikasi dengan jumlah fitur yang cukup banyak dan menghasilkan performa prediksi yang tinggi. Sementara itu, K-Means digunakan untuk mengelompokkan pelanggan berdasarkan karakteristik yang dimiliki sehingga dapat memberikan informasi tambahan mengenai pola pelanggan yang terbentuk.

Melalui penerapan kedua metode tersebut, penelitian ini bertujuan untuk menganalisis potensi *customer Churn* serta mengidentifikasi segmentasi pelanggan yang dapat digunakan sebagai pendukung strategi retensi pelanggan. Hasil penelitian diharapkan dapat memberikan informasi yang bermanfaat bagi perusahaan dalam memahami perilaku pelanggan, mengurangi tingkat *Churn*, dan mendukung pengambilan keputusan yang lebih efektif berdasarkan data.

II. TINJAUAN PUSTAKA

Penelitian mengenai *customer Churn* telah banyak dilakukan menggunakan berbagai pendekatan *data mining* dan *machine learning*. Salah satu penelitian dilakukan oleh Lukita dkk. yang membahas prediksi *customer Churn* menggunakan beberapa algoritma *machine learning*, yaitu *Random Forest*, *Logistic Regression*, *AdaBoost*, dan *XGBoost*. Penelitian tersebut menunjukkan bahwa algoritma *XGBoost* memberikan performa terbaik dibandingkan algoritma lainnya dalam melakukan prediksi *customer Churn*. Selain melakukan prediksi, penelitian tersebut juga mengidentifikasi faktor-faktor yang memiliki pengaruh besar terhadap *Churn* pelanggan, seperti *MonthlyCharges*, *PaperlessBilling*, *SeniorCitizen*, *PaymentMethod*, *MultipleLines*, dan *PhoneService*. Hasil penelitian tersebut menunjukkan bahwa penggunaan algoritma *XGBoost* dapat membantu perusahaan dalam memahami perilaku pelanggan serta mendukung penyusunan strategi retensi pelanggan yang lebih efektif [4].

Penelitian lain dilakukan oleh Adhitya dkk. yang membandingkan metode *CART* (*Classification and Regression Tree*) dan *Naive Bayes* untuk klasifikasi *customer Churn*. Evaluasi dilakukan menggunakan metrik akurasi, presisi, *recall*, dan *f1-score* pada beberapa skenario pembagian data latih dan data uji. Hasil penelitian menunjukkan bahwa kedua algoritma mampu digunakan untuk mengklasifikasikan *customer Churn* dengan performa yang cukup baik, meskipun *CART* menghasilkan nilai rata-rata akurasi yang lebih tinggi dibandingkan *Naive Bayes*. Penelitian ini membuktikan bahwa permasalahan *customer Churn* dapat diselesaikan

menggunakan pendekatan klasifikasi berbasis *machine learning* [5].

Selanjutnya, penelitian yang dilakukan oleh Iskandar dan Latifa mengembangkan sebuah website prediksi *customer Churn* pada perusahaan telekomunikasi menggunakan algoritma *K-Nearest Neighbor* (*KNN*). Sistem yang dibangun bertujuan membantu perusahaan dalam mengidentifikasi pelanggan yang berpotensi *Churn* sehingga tindakan pencegahan dapat dilakukan lebih awal. Penelitian tersebut menunjukkan bahwa implementasi model *machine learning* ke dalam aplikasi berbasis web dapat meningkatkan kemudahan penggunaan dan mendukung proses pengambilan keputusan secara lebih efektif [6].

Berdasarkan beberapa penelitian terdahulu tersebut, dapat diketahui bahwa *customer Churn* merupakan permasalahan yang banyak ditangani menggunakan teknik klasifikasi *machine learning*. Namun demikian, sebagian besar penelitian hanya berfokus pada proses prediksi *Churn* tanpa melakukan segmentasi pelanggan. Oleh karena itu, penelitian ini mengombinasikan algoritma *XGBoost* untuk prediksi *customer Churn* dan *K-Means* untuk segmentasi pelanggan sehingga tidak hanya mampu mengidentifikasi pelanggan yang berpotensi *Churn*, tetapi juga memberikan gambaran mengenai karakteristik kelompok pelanggan yang terbentuk. Selain itu, hasil model diimplementasikan ke dalam aplikasi web berbasis *Streamlit* agar lebih mudah digunakan dan dipahami oleh pengguna.

Data mining adalah proses yang menggunakan teknik statistik, matematika, kecerdasan buatan, dan *machine learning* untuk mengekstraksi dan mengidentifikasi informasi yang bermanfaat dan pengetahuan yang terkait dari database yang besar. Istilah *data mining* memiliki hakikat sebagai disiplin ilmu yang tujuan utamanya adalah untuk menemukan, menggali, atau menambang pengetahuan dari data atau informasi yang kita miliki. Proses menggali informasi dalam *data mining* melibatkan integrasi teknik dari berbagai disiplin ilmu, seperti teknologi database dan *data warehouse*, statistik, *machine learning*, komputasi dengan kinerja tinggi, *pattern recognition*, *neural network*, visualisasi data dan sebagainya [7].

Customer Churn adalah fenomena dimana pelanggan berhenti menggunakan layanan atau produk dari suatu perusahaan untuk periode waktu tertentu. Pelanggan yang melakukan *Churn* akan berpindah dari satu perusahaan ke pesaing lainnya, hal ini adalah tantangan utama bagi persaingan perusahaan yang kompetitif (Irmanda et al., 2019).

Retensi pelanggan adalah kemampuan perusahaan untuk mempertahankan pelanggan agar tetap menggunakan produk atau layanan dalam periode tertentu. Dalam konteks bisnis berbasis langganan, retensi menjadi sangat penting karena pelanggan yang bertahan lebih lama cenderung memberikan nilai yang lebih stabil bagi perusahaan. Pada kasus *customer Churn*, fokus utama bukan hanya mengenali pelanggan yang pergi, tetapi juga memahami faktor-faktor yang membuat pelanggan tetap bertahan sehingga perusahaan dapat menyusun strategi pencegahan yang lebih tepat.

Machine Learning adalah studi tentang algoritma untuk mempelajari bagaimana melakukan tugas-tugas tertentu yang dilakukan secara otomatis oleh orang-orang. Di sini, belajar mengacu pada kemampuan untuk melakukan berbagai kegiatan yang sudah ada atau untuk mengekstrapolasi kesimpulan baru dengan benar dari berbagai pola yang diamati sebelumnya [8].

Berbagai penelitian menunjukkan bahwa algoritma *machine learning* mampu menghasilkan performa yang baik dalam memprediksi *Churn* pelanggan. Salah satu algoritma yang banyak digunakan adalah Extreme Gradient Boosting (XGBoost). Algoritma ini merupakan metode *ensemble learning* berbasis *boosting* yang mampu menangani *data* dalam jumlah besar, mengurangi risiko *overfitting*, serta menghasilkan akurasi prediksi yang tinggi dibandingkan beberapa algoritma klasifikasi tradisional [9].


Selain melakukan prediksi *Churn*, perusahaan juga perlu memahami karakteristik pelanggan yang dimiliki. Salah satu pendekatan yang dapat digunakan adalah segmentasi pelanggan menggunakan teknik *clustering*. K-Means merupakan metode *clustering* yang mengelompokkan objek berdasarkan kemiripan karakteristik ke dalam sejumlah *cluster* tertentu. Hasil segmentasi pelanggan dapat digunakan sebagai dasar penyusunan strategi pemasaran, promosi, dan retensi pelanggan yang lebih tepat sasaran [10].

Permasalahan yang umum ditemukan pada *data Churn* adalah ketidakseimbangan distribusi kelas, di mana jumlah pelanggan yang tidak *Churn* jauh lebih banyak dibandingkan pelanggan *Churn*. Kondisi tersebut dapat menyebabkan model memiliki bias terhadap kelas mayoritas. Untuk mengatasi masalah tersebut digunakan metode *Synthetic Minority Over-sampling Technique* (SMOTE), yaitu teknik *oversampling* yang menghasilkan sampel sintesis pada kelas minoritas sehingga distribusi *data* menjadi lebih seimbang dan model dapat mempelajari pola *Churn* dengan lebih baik [11].

Selain menghasilkan prediksi, penelitian ini juga menerapkan pendekatan *Explainable artificial intelligence* (XAI) menggunakan metode SHAP (*SHapley Additive exPlanations*). Metode SHAP digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model sehingga keputusan yang dihasilkan dapat diinterpretasikan dengan lebih mudah. Pendekatan ini membantu perusahaan memahami faktor-faktor utama yang memengaruhi kemungkinan pelanggan melakukan *Churn* [12].

III. METODOLOGI PENELITIAN

Penelitian ini menggunakan pendekatan *data mining* untuk menganalisis perilaku pelanggan telekomunikasi dan memprediksi kemungkinan terjadinya *customer Churn*. Selain melakukan prediksi *Churn*, penelitian juga melakukan segmentasi pelanggan untuk memperoleh pemahaman yang lebih baik mengenai karakteristik masing-masing kelompok pelanggan. Tahapan penelitian mengacu pada kerangka kerja CRISP-DM (Cross Industry Standard Process for *Data Mining*) yang terdiri atas *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation*, dan *deployment*.



Gbr. 1 Alur CRISP-DM.

A. *Business Understanding*

Business Understanding merupakan tahap awal dalam metodologi CRISP-DM yang bertujuan untuk memahami permasalahan bisnis serta menentukan tujuan yang ingin dicapai melalui proses *data mining*. Pada penelitian ini, permasalahan utama yang diangkat adalah tingginya risiko *customer Churn* pada perusahaan telekomunikasi.

Customer Churn merupakan kondisi ketika pelanggan memutuskan untuk berhenti menggunakan layanan yang diberikan oleh perusahaan. Tingginya tingkat *Churn* dapat berdampak pada penurunan pendapatan perusahaan serta meningkatnya biaya untuk memperoleh pelanggan baru. Oleh karena itu, perusahaan perlu memiliki kemampuan untuk mengidentifikasi pelanggan yang berpotensi *Churn* sejak dini agar dapat dilakukan tindakan pencegahan melalui strategi retensi pelanggan.

Selain permasalahan *Churn*, perusahaan juga perlu memahami karakteristik pelanggan yang dimiliki. Setiap pelanggan memiliki perilaku dan pola penggunaan layanan yang berbeda sehingga diperlukan segmentasi pelanggan untuk membantu perusahaan memahami kelompok pelanggan yang memiliki karakteristik serupa.

Berdasarkan permasalahan tersebut, tujuan penelitian ini adalah membangun model *machine learning* yang mampu memprediksi *customer Churn* serta melakukan segmentasi pelanggan menggunakan teknik *clustering*. Hasil analisis kemudian diimplementasikan ke dalam aplikasi web berbasis Streamlit agar dapat digunakan secara interaktif oleh pengguna.

B. Data Understanding

Penelitian ini menggunakan *Telco Customer Churn Dataset* yang diperoleh dari platform Kaggle. *Dataset* tersebut berisi informasi pelanggan perusahaan telekomunikasi yang digunakan untuk menganalisis perilaku pelanggan serta memprediksi kemungkinan terjadinya *customer Churn*.

Dataset terdiri dari 7.043 *data* pelanggan dan 21 atribut, yang mencakup informasi demografis pelanggan, layanan yang digunakan, informasi kontrak, metode pembayaran, biaya layanan, serta status *Churn* pelanggan. Adapun atribut yang terdapat dalam *dataset* meliputi *customerID*, *gender*, *SeniorCitizen*, *Partner*, *Dependents*, *tenure*, *PhoneService*, *MultipleLines*, *InternetService*, *OnlineSecurity*, *OnlineBackup*, *DeviceProtection*, *TechSupport*, *StreamingTV*, *StreamingMovies*, *Contract*, *PaperlessBilling*, *PaymentMethod*, *MonthlyCharges*, *TotalCharges*, dan *Churn*.

Pada penelitian ini, atribut *Churn* digunakan sebagai variabel target dalam proses klasifikasi. Variabel tersebut menunjukkan status pelanggan, yaitu pelanggan yang tetap menggunakan layanan (*No*) atau pelanggan yang berhenti berlangganan (*Yes*). Sementara itu, atribut lainnya digunakan sebagai variabel prediktor yang berperan dalam proses pembentukan model prediksi *Churn* dan segmentasi pelanggan.

C. Data Preparation

Tahap *data preparation* dilakukan untuk menyiapkan *dataset Telco Customer Churn* agar siap digunakan dalam proses pemodelan. Pada tahap ini, *data* dibersihkan, diubah ke bentuk numerik, diseimbangkan, dan disesuaikan skala fiturnya. Tahap ini penting karena kualitas preprocessing sangat memengaruhi performa model, terutama pada *data Churn* yang bersifat imbalanced..

1) *Missing Value*: dilakukan pemeriksaan terhadap nilai hilang (*missing value*) sebelum proses pemodelan. Salah satu atribut yang membutuhkan perhatian adalah *TotalCharges* karena pada beberapa baris terdapat nilai kosong atau bertipe tidak numerik. Oleh karena itu, atribut tersebut dikonversi menjadi numerik terlebih dahulu, kemudian nilai hilang diisi menggunakan median agar distribusi *data* tidak terlalu terpengaruh oleh nilai ekstrem. Proses ini dilakukan untuk menjaga kualitas *data* agar model dapat belajar dari informasi yang konsisten.

2) *Data Cleaning*: atribut *customerID* dihapus karena hanya berfungsi sebagai identitas pelanggan dan tidak memberikan kontribusi terhadap prediksi. Variabel target yang digunakan adalah *Churn*, sedangkan seluruh atribut lainnya digunakan sebagai fitur prediktor. Pemilihan fitur dilakukan untuk memastikan bahwa model hanya mempelajari atribut yang relevan dengan perilaku pelanggan.

3) *Encoding*: *Dataset Telco Customer Churn* memiliki banyak atribut kategorikal seperti *gender*, *Partner*, *Dependents*, *InternetService*, *Contract*, dan *PaymentMethod*. Algoritma XGBoost dan K-Means memerlukan input numerik, sehingga atribut kategorikal tersebut ditransformasikan ke bentuk numerik menggunakan teknik encoding. Dalam implementasi penelitian ini digunakan one-

hot encoding agar kategori nominal tidak diberi urutan semu dan dapat diolah secara lebih tepat oleh model klasifikasi maupun *clustering* [13].

4) *Correlation Heat Map*: dilakukan analisis korelasi antar fitur numerik untuk memahami hubungan antar variabel. Visualisasi *correlation heat map* digunakan untuk melihat keterkaitan antara *tenure*, *MonthlyCharges*, *TotalCharges*, dan *Churn*. Hasil korelasi membantu peneliti memahami fitur mana yang memiliki hubungan lebih kuat terhadap status *Churn* pelanggan dan menjadi dasar dalam pembahasan hasil penelitian.

5) *Data Balancing*: *Dataset Churn* umumnya memiliki distribusi kelas yang tidak seimbang, di mana jumlah pelanggan yang tidak *Churn* lebih banyak dibandingkan pelanggan *Churn*. Kondisi ini dapat menyebabkan model cenderung bias ke kelas mayoritas dan kurang sensitif terhadap kelas minoritas. Untuk mengatasi hal tersebut, penelitian ini menggunakan *Synthetic Minority Over-sampling Technique* (SMOTE) pada *data* latih. Teknik ini menghasilkan sampel sintesis pada kelas minoritas sehingga distribusi *data* menjadi lebih seimbang dan model dapat mengenali pola *Churn* dengan lebih baik.

6) *Data Standardized*: karena algoritma K-Means berbasis jarak, maka fitur numerik perlu disetarakan skalanya agar fitur dengan rentang nilai besar tidak mendominasi proses pembentukan *cluster*. Oleh karena itu, penelitian ini menerapkan *StandardScaler* sebelum proses *clustering*. Standardisasi mengubah *data* menjadi bentuk dengan rata-rata nol dan simpangan baku satu, sehingga setiap fitur memiliki kontribusi yang relatif seimbang dalam perhitungan jarak.

7) *Split Train and Test Set*: Setelah preprocessing selesai, *dataset* dibagi menjadi *data* latih dan *data* uji dengan proporsi 80:20. Pembagian dilakukan menggunakan *stratified split* agar distribusi kelas *Churn* dan non-*Churn* tetap terjaga pada *data* latih maupun *data* uji. Langkah ini penting untuk menghindari bias evaluasi dan memastikan model diuji pada *data* yang merepresentasikan kondisi asli *dataset*.

D. Modeling

Penelitian ini menggunakan dua metode utama, yaitu XGBoost untuk klasifikasi dan K-Means untuk segmentasi pelanggan. Pemilihan XGBoost didasarkan pada kemampuannya dalam menangani *data* tabular dan menghasilkan performa prediksi yang tinggi, sedangkan K-Means dipilih karena sederhana, efisien, dan efektif untuk mengelompokkan pelanggan berdasarkan kemiripan karakteristik.

1) XGBoost Classification

Dalam penelitian ini, XGBoost digunakan untuk memprediksi status *Churn* pelanggan berdasarkan atribut yang telah diproses. Model dilatih menggunakan *data* hasil preprocessing dan SMOTE, kemudian diuji pada *data* yang

belum pernah dilihat sebelumnya. Penggunaan XGBoost pada permasalahan *Churn prediction* telah banyak digunakan karena mampu memberikan hasil yang kompetitif pada *data* pelanggan telekomunikasi.

2) K-Means Clustering

Digunakan untuk mengelompokkan pelanggan ke dalam beberapa *cluster* berdasarkan karakteristik yang mirip. Penentuan jumlah *cluster* dilakukan menggunakan Elbow Method dengan melihat perubahan nilai Within Cluster Sum of Squares (WCSS). Pada penelitian ini diperoleh tiga *cluster* sebagai jumlah yang paling sesuai untuk menggambarkan segmentasi pelanggan. K-Means dipilih karena mampu memberikan segmentasi yang mudah diinterpretasikan dan berguna untuk mendukung strategi pemasaran maupun retensi pelanggan.

E. Evaluation

Evaluasi model klasifikasi dilakukan menggunakan beberapa metrik, yaitu *accuracy*, *precision*, *recall*, F1-score, dan ROC-AUC. Metrik tersebut digunakan untuk menilai seberapa baik model dalam membedakan pelanggan *Churn* dan non-*Churn*. Selain itu, confusion matrix digunakan untuk melihat jumlah prediksi benar dan salah secara lebih rinci. Pada hasil penelitian ini juga digunakan feature importance untuk mengetahui atribut yang paling berpengaruh terhadap keputusan model, sedangkan SHAP digunakan untuk menjelaskan kontribusi masing-masing fitur terhadap prediksi *Churn*.

Untuk evaluasi *clustering*, digunakan *Silhouette Score* yang menunjukkan tingkat keterpisahan antar *cluster*. Nilai *Silhouette Score* yang diperoleh pada penelitian ini menunjukkan bahwa *cluster* telah terbentuk, meskipun batas antar *cluster* masih belum terlalu kuat. Hal ini masih dapat diterima karena tujuan utama *clustering* pada penelitian ini adalah segmentasi awal pelanggan, bukan pembentukan kelompok yang sepenuhnya terpisah sempurna.

F. Deployment

Tahap akhir penelitian adalah implementasi model ke dalam aplikasi web menggunakan Streamlit. Aplikasi dikembangkan agar hasil analisis dapat diakses secara interaktif tanpa harus menjalankan kode Python secara langsung. Fitur yang ditampilkan meliputi ringkasan *dataset*, visualisasi *data*, hasil evaluasi model, interpretasi fitur penting, prediksi *Churn* pelanggan, serta segmentasi pelanggan. Implementasi ini bertujuan agar hasil penelitian tidak hanya berhenti pada model, tetapi juga dapat digunakan sebagai alat bantu pengambilan keputusan berbasis *data*.


IV. HASIL DAN PEMBAHASAN

A. Hasil Data Understanding

Penelitian ini menggunakan *dataset* Telco Customer Churn yang terdiri dari 7.043 *data* pelanggan dengan 21 atribut. *Dataset* memuat informasi demografis pelanggan, layanan yang digunakan, jenis kontrak, metode pembayaran, biaya layanan, serta status *Churn* pelanggan. Variabel target yang digunakan adalah atribut *Churn* yang menunjukkan apakah

pelanggan berhenti menggunakan layanan (Yes) atau tetap menggunakan layanan (No).

Berdasarkan hasil eksplorasi *data*, diketahui bahwa distribusi kelas pada *dataset* tidak seimbang. Jumlah pelanggan yang tidak melakukan *Churn* lebih besar dibandingkan pelanggan yang melakukan *Churn*. Dari total 7.043 pelanggan, sekitar 26,5% pelanggan termasuk kategori *Churn*, sedangkan sisanya merupakan pelanggan aktif. Ketidakseimbangan distribusi kelas ini menjadi salah satu tantangan dalam membangun model klasifikasi karena model berpotensi lebih sering memprediksi kelas mayoritas dibandingkan kelas minoritas.



Gbr. 2 Distribusi Churn.


Berdasarkan gambar 2 terlihat bahwa jumlah pelanggan non-*Churn* mendominasi *dataset* dibandingkan pelanggan *Churn*. Kondisi ini umum ditemukan pada kasus *customer Churn* karena sebagian besar pelanggan cenderung tetap menggunakan layanan yang telah mereka gunakan dalam jangka waktu tertentu. Ketidakseimbangan distribusi kelas (*class imbalance*) tersebut dapat menyebabkan model *machine learning* lebih fokus mempelajari karakteristik kelas mayoritas sehingga performa prediksi terhadap kelas minoritas menjadi kurang optimal.

Meskipun jumlah pelanggan *Churn* lebih sedikit, kelompok ini memiliki nilai bisnis yang sangat penting karena berkaitan langsung dengan potensi kehilangan pelanggan (*customer loss*) dan penurunan pendapatan perusahaan. Kegagalan dalam mengidentifikasi pelanggan yang berpotensi *Churn* dapat menyebabkan perusahaan kehilangan kesempatan untuk melakukan tindakan retensi secara dini. Oleh karena itu, kemampuan model dalam mengenali pelanggan *Churn* menjadi salah satu aspek yang perlu diperhatikan dalam penelitian ini.

Untuk mengatasi permasalahan ketidakseimbangan *data* tersebut, penelitian ini menerapkan teknik *Synthetic Minority Over-sampling Technique* (SMOTE) pada tahap preprocessing. SMOTE bekerja dengan menghasilkan *data* sintesis baru pada kelas minoritas berdasarkan karakteristik *data* yang sudah ada sehingga distribusi jumlah *data* antar kelas menjadi lebih seimbang. Berbeda dengan teknik duplikasi *data* biasa (*random oversampling*), SMOTE mampu menghasilkan variasi *data* baru yang lebih representatif sehingga dapat mengurangi risiko overfitting pada model.

Penerapan SMOTE diharapkan dapat meningkatkan kemampuan model XGBoost dalam mengenali pola pelanggan *Churn* serta mengurangi kecenderungan model untuk hanya memprediksi kelas mayoritas. Dengan distribusi *data* yang lebih seimbang, proses pelatihan model dapat menghasilkan performa klasifikasi yang lebih baik, terutama pada metrik *recall* dan *precision* untuk kelas *Churn* yang menjadi fokus utama dalam penelitian ini.

Selain distribusi *Churn*, dilakukan pula analisis hubungan antara jenis kontrak pelanggan dan status *Churn*.




Gbr. 3 Hubungan Jenis Kontrak terhadap *Customer Churn*.

Berdasarkan gambar 3 terlihat bahwa pelanggan dengan kontrak *Month-to-Month* memiliki tingkat *Churn* yang jauh lebih tinggi dibandingkan pelanggan dengan kontrak satu tahun maupun dua tahun. Temuan ini menunjukkan bahwa pelanggan yang tidak terikat kontrak jangka panjang memiliki kecenderungan lebih besar untuk berpindah ke penyedia layanan lain. Sebaliknya, pelanggan dengan kontrak tahunan atau dua tahunan cenderung memiliki loyalitas yang lebih tinggi sehingga risiko *Churn* relatif lebih rendah.

Temuan ini memberikan indikasi awal bahwa atribut *Contract* berpotensi menjadi salah satu fitur penting dalam model prediksi *Churn* yang dibangun.

Untuk memahami hubungan antar atribut numerik, dilakukan analisis korelasi menggunakan heatmap.



Gbr. 4 Correlation Heatmap.

Hasil korelasi menunjukkan bahwa atribut *tenure* memiliki hubungan positif yang cukup kuat dengan *TotalCharges*. Hal ini menunjukkan bahwa semakin lama pelanggan menggunakan layanan, semakin besar total biaya yang telah dikeluarkan pelanggan. Sementara itu, korelasi antara *MonthlyCharges* dan *Churn* menunjukkan bahwa pelanggan dengan biaya bulanan yang lebih tinggi memiliki kecenderungan lebih besar untuk melakukan *Churn* dibandingkan pelanggan dengan biaya bulanan yang lebih rendah.

Meskipun korelasi tidak secara langsung menunjukkan hubungan sebab-akibat, hasil ini memberikan gambaran awal mengenai atribut yang berpotensi berkontribusi dalam proses prediksi *Churn*.

B. Hasil Data Preparation

Tahap *data preparation* dilakukan untuk menghasilkan *dataset* yang siap digunakan pada proses pemodelan. Beberapa tahapan yang dilakukan meliputi pemeriksaan missing value, transformasi *data* kategorikal, penyeimbangan *data* menggunakan SMOTE, dan standarisasi *data* untuk kebutuhan *clustering*.

Berdasarkan hasil pemeriksaan *dataset*, ditemukan bahwa atribut *TotalCharges* mengandung beberapa nilai kosong akibat proses penyimpanan *data*. Oleh karena itu, atribut tersebut dikonversi ke format numerik dan nilai yang hilang ditangani sebelum proses pemodelan dilakukan.

Selanjutnya, atribut kategorikal seperti gender, Partner, Dependents, *InternetService*, *Contract*, dan *PaymentMethod* ditransformasikan ke bentuk numerik menggunakan teknik encoding. Transformasi ini diperlukan karena algoritma *machine learning* tidak dapat memproses *data* kategorikal secara langsung.

Setelah proses encoding selesai, *dataset* dibagi menjadi *data* latih dan *data* uji menggunakan rasio 80:20 dengan teknik stratifikasi untuk menjaga proporsi kelas *Churn* dan non-*Churn* pada kedua kelompok *data*.

Ada distribusi kelas tidak seimbang, dilakukan penerapan *Synthetic Minority Over-sampling Technique* (SMOTE) pada *data* latih. Teknik ini menghasilkan sampel sintesis pada kelas minoritas sehingga distribusi kelas menjadi lebih seimbang dan model dapat mempelajari pola *Churn* secara lebih efektif.

Selain itu, dilakukan standarisasi fitur numerik menggunakan *StandardScaler* sebelum proses *clustering* menggunakan algoritma K-Means. Standarisasi dilakukan agar seluruh fitur memiliki skala yang sebanding sehingga tidak ada atribut tertentu yang mendominasi proses pembentukan *cluster*.

Tahap preprocessing memiliki peran penting dalam meningkatkan kualitas model. Tanpa proses encoding, balancing, dan standarisasi, performa model klasifikasi maupun *clustering* berpotensi menurun. Oleh karena itu, tahapan ini menjadi fondasi utama sebelum dilakukan pembangunan model XGBoost dan K-Means.

C. Hasil Pemodelan Klasifikasi XGBoost

Pada penelitian ini, algoritma XGBoost digunakan untuk membangun model prediksi *customer Churn*. Pemilihan XGBoost didasarkan pada kemampuannya dalam menangani

data berukuran besar, mengatasi hubungan non-linear antar variabel, serta menghasilkan performa klasifikasi yang tinggi dibandingkan metode klasifikasi tradisional.

Sebelum proses pelatihan model dilakukan, *dataset* telah melalui tahap preprocessing berupa encoding *data* kategorikal, pembagian *data* latih dan *data* uji, serta penyeimbangan *data* menggunakan metode SMOTE. Model kemudian dilatih menggunakan *data* latih dan dievaluasi menggunakan *data* uji untuk mengukur kemampuan prediksi terhadap pelanggan yang berpotensi *Churn*.

===== EVALUATION =====

Accuracy : 0.7665

Precision: 0.5527

Recall : 0.6310

F1-Score : 0.5893

ROC AUC : 0.8256

Gbr. 5 Hasil Akurasi.

Berdasarkan hasil evaluasi, model memperoleh nilai *accuracy* sebesar 76,65%. Nilai tersebut menunjukkan bahwa sebagian besar *data* pelanggan berhasil diklasifikasikan dengan benar oleh model. Namun demikian, pada kasus *customer Churn*, *accuracy* tidak dapat dijadikan satu-satunya indikator performa karena distribusi kelas pada *dataset* tidak seimbang.


Nilai *precision* sebesar 55,27% menunjukkan bahwa dari seluruh pelanggan yang diprediksi akan *Churn*, sekitar 55% benar-benar termasuk pelanggan *Churn*. Sementara itu, nilai *recall* sebesar 63,10% menunjukkan bahwa model mampu mengidentifikasi sekitar 63% pelanggan *Churn* yang sebenarnya terdapat pada *dataset*.

Dalam konteks bisnis telekomunikasi, *recall* memiliki peran yang sangat penting karena tujuan utama perusahaan adalah mengidentifikasi sebanyak mungkin pelanggan yang berpotensi meninggalkan layanan. Kesalahan dalam mendeteksi pelanggan *Churn* dapat menyebabkan perusahaan kehilangan kesempatan untuk melakukan strategi retensi pelanggan.

Selain itu, model menghasilkan nilai ROC-AUC sebesar 82,56%. Nilai tersebut menunjukkan bahwa model memiliki kemampuan diskriminasi yang baik dalam membedakan pelanggan *Churn* dan non-*Churn*. Secara umum, nilai ROC-AUC di atas 0,80 dapat dikategorikan sebagai performa klasifikasi yang baik sehingga model yang dibangun dapat digunakan sebagai alat bantu pengambilan keputusan dalam manajemen pelanggan.

1) Analisis Confusion Matrix

Untuk mengetahui performa model secara lebih rinci, dilakukan analisis menggunakan confusion matrix.



Gbr. 6 Confusion Matrix Model XGBoost.


Confusion matrix digunakan untuk menggambarkan jumlah prediksi yang benar maupun salah yang dihasilkan oleh model. Matriks ini terdiri atas empat komponen utama yaitu True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN).

Nilai True Positive menunjukkan jumlah pelanggan *Churn* yang berhasil diprediksi dengan benar oleh model. Sebaliknya, False Negative menunjukkan pelanggan *Churn* yang gagal dikenali dan diprediksi sebagai pelanggan non-*Churn*. Dalam kasus *customer Churn*, False Negative merupakan kesalahan yang paling perlu diperhatikan karena pelanggan berpotensi meninggalkan layanan tanpa mendapatkan tindakan pencegahan dari perusahaan.

Berdasarkan confusion matrix yang diperoleh, model mampu mengenali sebagian besar pelanggan non-*Churn* dengan baik, serta berhasil mengidentifikasi pelanggan *Churn* dalam jumlah yang cukup tinggi. Hasil ini sejalan dengan nilai *recall* yang diperoleh pada tahap evaluasi sebelumnya.

2) Analisis ROC Curve

Selain confusion matrix, evaluasi model juga dilakukan menggunakan ROC Curve untuk melihat kemampuan model dalam membedakan kedua kelas.



Gbr. 7 ROC Curve Model XGBoost.

ROC Curve (Receiver Operating Characteristic Curve) menggambarkan hubungan antara True Positive Rate (TPR) dan False Positive Rate (FPR) pada berbagai nilai threshold. Kurva ini digunakan untuk mengevaluasi kemampuan model

dalam membedakan dua kelas, yaitu pelanggan *Churn* dan non-*Churn*. Semakin dekat posisi kurva terhadap sudut kiri atas, semakin baik kemampuan model dalam melakukan klasifikasi karena menunjukkan nilai TPR yang tinggi dan FPR yang rendah.

Berdasarkan Gambar 7, kurva ROC yang dihasilkan oleh model XGBoost berada jauh di atas garis diagonal yang merepresentasikan *random classifier*. Kondisi tersebut menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan pelanggan yang berpotensi *Churn* dengan pelanggan yang tidak *Churn*. Jika kurva berada mendekati garis diagonal, maka performa model tidak jauh berbeda dengan prediksi secara acak. Namun, hasil yang diperoleh pada penelitian ini menunjukkan bahwa model mampu mengenali pola-pola penting yang terdapat pada *data* pelanggan sehingga menghasilkan performa klasifikasi yang lebih baik.

Nilai ROC-AUC sebesar 82,56% mengindikasikan bahwa model memiliki kemampuan diskriminasi yang tinggi dalam membedakan kedua kelas. Secara umum, nilai AUC di atas 80% dapat dikategorikan sebagai performa yang baik dalam permasalahan klasifikasi. Nilai tersebut menunjukkan bahwa ketika model diberikan dua pelanggan secara acak, yaitu satu pelanggan *Churn* dan satu pelanggan non-*Churn*, model memiliki peluang sebesar 82,56% untuk memberikan skor prediksi yang lebih tinggi kepada pelanggan yang benar-benar *Churn*.


Hasil ini menunjukkan bahwa model XGBoost tidak hanya mampu menghasilkan tingkat akurasi yang baik, tetapi juga memiliki kemampuan yang kuat dalam mengenali pelanggan yang berisiko *Churn*. Kemampuan tersebut sangat penting dalam konteks bisnis karena memungkinkan perusahaan melakukan tindakan pencegahan secara lebih dini terhadap pelanggan yang berpotensi meninggalkan layanan. Dengan demikian, perusahaan dapat mengalokasikan sumber daya retensi secara lebih efektif kepada pelanggan yang memiliki risiko *Churn* tinggi.

Selain itu, hasil ROC-AUC yang cukup tinggi juga memperkuat hasil evaluasi sebelumnya yang diperoleh dari confusion matrix, *accuracy*, *precision*, dan *recall*. Kombinasi berbagai metrik evaluasi tersebut menunjukkan bahwa model yang dibangun memiliki performa yang konsisten dan layak digunakan sebagai alat bantu dalam mendukung pengambilan keputusan terkait strategi retensi pelanggan pada perusahaan telekomunikasi.

D. Analisis Feature Importance

Selain melakukan prediksi *Churn*, penelitian ini juga bertujuan untuk mengetahui faktor-faktor yang paling berpengaruh terhadap keputusan pelanggan untuk berhenti menggunakan layanan telekomunikasi. Untuk memperoleh informasi tersebut digunakan fitur Feature Importance yang disediakan oleh algoritma XGBoost.

Feature Importance menunjukkan tingkat kontribusi masing-masing variabel dalam proses pembentukan model prediksi. Semakin tinggi nilai importance suatu fitur, maka semakin besar pengaruh fitur tersebut terhadap hasil prediksi *Churn*.



Gbr. 8 Feature Importance Model XGBoost.

Berdasarkan gambar 8, diketahui bahwa variabel *PaymentMethod_Electronic check* merupakan faktor yang memiliki pengaruh paling besar terhadap prediksi *Churn* pelanggan. Hasil ini menunjukkan bahwa pelanggan yang menggunakan metode pembayaran *Electronic check* cenderung memiliki risiko *Churn* yang lebih tinggi dibandingkan metode pembayaran lainnya.

Faktor penting berikutnya adalah *PaperlessBilling_Yes* dan *InternetService_Fiber optic*. Pelanggan yang menggunakan layanan internet fiber optic menunjukkan kecenderungan *Churn* yang relatif lebih tinggi. Kondisi tersebut dapat disebabkan oleh tingginya ekspektasi pelanggan terhadap kualitas layanan internet sehingga ketika kualitas layanan tidak sesuai harapan, pelanggan lebih mudah berpindah ke penyedia layanan lain.

Selain itu, variabel *Contract_Two year* dan *Contract_One year* juga memberikan kontribusi yang cukup besar terhadap model. Temuan ini menunjukkan bahwa jenis kontrak memiliki hubungan yang kuat dengan loyalitas pelanggan. Pelanggan dengan kontrak jangka panjang cenderung memiliki risiko *Churn* yang lebih rendah dibandingkan pelanggan dengan kontrak bulanan (month-to-month).

Variabel *tenure* atau lama berlangganan juga termasuk dalam fitur yang memiliki pengaruh tinggi. Semakin lama pelanggan menggunakan layanan perusahaan, semakin kecil kemungkinan pelanggan tersebut melakukan *Churn*. Hal ini mengindikasikan adanya hubungan positif antara loyalitas pelanggan dan durasi penggunaan layanan.


Hasil Feature Importance memberikan informasi penting bagi perusahaan dalam menyusun strategi retensi pelanggan. Perusahaan dapat memfokuskan perhatian pada pelanggan dengan metode pembayaran tertentu, pelanggan pengguna layanan fiber optic, serta pelanggan dengan kontrak bulanan yang memiliki risiko *Churn* lebih tinggi.

E. Explainable artificial intelligence (XAI) SHAP

Meskipun model XGBoost memiliki tingkat akurasi yang cukup baik dalam memprediksi *customer Churn*, proses pengambilan keputusan model masih tergolong sebagai black box sehingga sulit dipahami secara langsung oleh pengguna. Oleh karena itu, penelitian ini menerapkan pendekatan *Explainable artificial intelligence (XAI)* menggunakan metode *SHapley Additive exPlanations (SHAP)* untuk menjelaskan bagaimana setiap fitur memberikan kontribusi terhadap hasil prediksi yang dihasilkan oleh model.

SHAP bekerja berdasarkan konsep nilai Shapley dari teori permainan (game theory) yang digunakan untuk mengukur kontribusi masing-masing variabel terhadap suatu prediksi. Melalui pendekatan ini, setiap fitur diberikan nilai kontribusi sehingga dapat diketahui apakah suatu fitur meningkatkan atau menurunkan kemungkinan pelanggan melakukan *Churn*. Dengan demikian, model tidak hanya menghasilkan prediksi, tetapi juga mampu memberikan penjelasan yang lebih transparan mengenai alasan di balik prediksi tersebut.

Gambar 9 menunjukkan hasil visualisasi SHAP Summary Plot yang menampilkan fitur-fitur dengan pengaruh terbesar terhadap prediksi *customer Churn*. Semakin tinggi posisi suatu fitur pada grafik, semakin besar pula kontribusinya terhadap keputusan model. Selain itu, warna pada grafik menunjukkan nilai fitur, di mana warna merah merepresentasikan nilai yang lebih tinggi dan warna biru merepresentasikan nilai yang lebih rendah.



Gbr. 9 SHAP Summary Plot.

Berdasarkan hasil visualisasi SHAP, diketahui bahwa fitur *PaymentMethod_Electronic check*, *InternetService_Fiber optic*, *tenure*, dan *MonthlyCharges* merupakan variabel yang paling berpengaruh dalam menentukan apakah pelanggan berpotensi *Churn* atau tidak. Dominasi fitur-fitur tersebut menunjukkan bahwa faktor metode pembayaran, jenis layanan internet, lama berlangganan, dan biaya layanan menjadi indikator penting dalam perilaku pelanggan telekomunikasi.

Fitur *tenure* memiliki pengaruh yang cukup signifikan terhadap prediksi *Churn*. Hasil SHAP menunjukkan bahwa pelanggan dengan masa berlangganan yang rendah cenderung memiliki nilai kontribusi positif terhadap *Churn*, sehingga peluang untuk berhenti menggunakan layanan menjadi lebih besar. Sebaliknya, pelanggan yang telah berlangganan dalam

jangka waktu yang lama cenderung memiliki risiko *Churn* yang lebih rendah. Temuan ini menunjukkan bahwa loyalitas pelanggan umumnya meningkat seiring bertambahnya durasi penggunaan layanan.

Selain itu, fitur *MonthlyCharges* juga memberikan kontribusi yang cukup besar terhadap keputusan model. Pelanggan dengan biaya bulanan yang relatif tinggi cenderung memiliki kemungkinan *Churn* yang lebih besar dibandingkan pelanggan dengan biaya bulanan yang lebih rendah. Kondisi tersebut mengindikasikan bahwa faktor biaya masih menjadi salah satu pertimbangan utama pelanggan dalam mempertahankan atau menghentikan langganan layanan telekomunikasi. Apabila pelanggan merasa biaya yang dibayarkan tidak sebanding dengan manfaat yang diperoleh, maka kecenderungan untuk berpindah ke penyedia layanan lain akan meningkat.

Fitur *InternetService_Fiber optic* juga termasuk variabel yang memiliki pengaruh kuat terhadap prediksi model. Hal ini menunjukkan bahwa jenis layanan internet yang digunakan pelanggan berkaitan dengan tingkat kepuasan pelanggan terhadap layanan yang diterima. Pada beberapa kasus, pelanggan pengguna layanan fiber optic memiliki ekspektasi yang lebih tinggi terhadap kualitas layanan sehingga lebih sensitif terhadap gangguan maupun ketidaksesuaian layanan yang diterima.


Sementara itu, fitur *PaymentMethod_Electronic check* menempati posisi teratas dalam visualisasi SHAP. Hasil ini mengindikasikan bahwa metode pembayaran yang digunakan pelanggan memiliki hubungan yang cukup erat dengan perilaku *Churn*. Pelanggan yang menggunakan metode pembayaran *Electronic check* cenderung memiliki risiko *Churn* yang lebih tinggi dibandingkan metode pembayaran lainnya. Temuan ini sejalan dengan beberapa penelitian *customer Churn* sebelumnya yang menunjukkan bahwa metode pembayaran tertentu dapat menjadi indikator perilaku pelanggan dalam mempertahankan layanan.

Secara keseluruhan, hasil interpretasi menggunakan SHAP memperkuat temuan pada analisis Feature Importance yang telah dilakukan sebelumnya. Selain mampu menghasilkan performa prediksi yang baik, model XGBoost yang dibangun juga dapat memberikan informasi mengenai faktor-faktor utama yang memengaruhi keputusan pelanggan untuk melakukan *Churn*. Informasi tersebut sangat bermanfaat bagi perusahaan dalam menyusun strategi retensi pelanggan yang lebih tepat sasaran, seperti memberikan perhatian khusus kepada pelanggan baru, pelanggan dengan biaya bulanan tinggi, maupun pelanggan yang menggunakan metode pembayaran tertentu yang memiliki risiko *Churn* lebih besar. *Segmentasi K-Means Clustering*

Selain melakukan prediksi *Churn*, penelitian ini juga menerapkan teknik segmentasi pelanggan menggunakan algoritma K-Means *Clustering*. Tujuan dari proses segmentasi adalah mengelompokkan pelanggan yang memiliki karakteristik serupa sehingga perusahaan dapat menerapkan strategi pemasaran dan retensi yang lebih tepat sasaran.

Sebelum proses *clustering* dilakukan, data pelanggan terlebih dahulu dinormalisasi menggunakan StandardScaler

untuk memastikan seluruh atribut memiliki skala yang seragam. Jumlah *cluster* ditentukan menggunakan metode Elbow dan menghasilkan nilai optimal sebanyak tiga *cluster*.



Gbr. 10 Elbow Methods.



Gbr. 11 Visualisasi *Clustering* Pelanggan.

Berdasarkan hasil *clustering*, pelanggan berhasil dikelompokkan ke dalam tiga segmen utama dengan karakteristik yang berbeda. Proses segmentasi ini bertujuan untuk membantu perusahaan memahami pola perilaku pelanggan sehingga strategi pemasaran dan retensi dapat disesuaikan dengan karakteristik masing-masing kelompok.

Cluster pertama berisi pelanggan dengan tingkat penggunaan layanan yang relatif rendah serta biaya langganan yang lebih kecil. Kelompok ini umumnya terdiri atas pelanggan baru atau pelanggan yang belum memanfaatkan layanan secara maksimal. Karakteristik tersebut menunjukkan bahwa tingkat keterikatan pelanggan terhadap perusahaan masih relatif rendah sehingga diperlukan upaya untuk meningkatkan keterlibatan pelanggan, misalnya melalui program promosi, edukasi layanan, atau penawaran fitur tambahan yang sesuai dengan kebutuhan mereka.

Cluster kedua didominasi oleh pelanggan dengan biaya bulanan yang lebih tinggi namun memiliki masa berlangganan yang relatif pendek. Karakteristik ini menunjukkan bahwa pelanggan dalam kelompok tersebut telah mengeluarkan biaya yang cukup besar, tetapi belum memiliki loyalitas yang kuat terhadap perusahaan. Kondisi ini menjadikan *cluster* kedua sebagai kelompok yang memiliki potensi *Churn* lebih tinggi dibandingkan *cluster* lainnya. Oleh karena itu, perusahaan perlu memberikan perhatian khusus kepada pelanggan pada *cluster* ini, misalnya dengan meningkatkan kualitas layanan, memberikan penawaran khusus, atau menyediakan program

retensi yang lebih personal untuk mencegah pelanggan berpindah ke kompetitor.

Cluster ketiga terdiri atas pelanggan dengan masa berlangganan yang lebih panjang dan tingkat penggunaan layanan yang tinggi. Kelompok ini dapat dikategorikan sebagai pelanggan loyal karena telah menggunakan layanan perusahaan dalam jangka waktu yang lama serta memberikan kontribusi yang signifikan terhadap pendapatan perusahaan. Pelanggan pada *cluster* ini umumnya memiliki tingkat kepuasan yang lebih baik dan cenderung mempertahankan penggunaan layanan. Oleh karena itu, perusahaan perlu menjaga kualitas layanan yang diberikan serta mempertahankan hubungan yang baik dengan pelanggan melalui program loyalitas, penghargaan pelanggan, maupun layanan pelanggan yang responsif.

Hasil segmentasi pelanggan ini memberikan informasi yang berharga bagi perusahaan karena setiap kelompok memiliki karakteristik, kebutuhan, dan tingkat risiko yang berbeda. Dengan memahami profil masing-masing *cluster*, perusahaan dapat menyusun strategi bisnis yang lebih efektif dan terarah. Sebagai contoh, perusahaan dapat memfokuskan program loyalitas pada pelanggan di *cluster* ketiga, meningkatkan engagement pelanggan pada *cluster* pertama, serta mengutamakan strategi retensi pada pelanggan di *cluster* kedua yang memiliki risiko *Churn* lebih tinggi. Dengan demikian, hasil *clustering* tidak hanya memberikan gambaran mengenai karakteristik pelanggan, tetapi juga dapat menjadi dasar dalam pengambilan keputusan bisnis yang lebih tepat sasaran.

F. Evaluasi Kualitas *Clustering*

Untuk mengevaluasi kualitas hasil segmentasi pelanggan digunakan metrik *Silhouette Score*.

Silhouette Score: 0.21933537572959633

Gbr. 12 Hasil Evaluasi *Silhouette Score*.

Berdasarkan hasil pengujian diperoleh nilai *Silhouette Score* sebesar 0,2193. Nilai tersebut menunjukkan bahwa struktur *cluster* yang terbentuk berada pada kategori cukup (fair *clustering*). Secara umum, *Silhouette Score* digunakan untuk mengukur kualitas hasil *clustering* dengan melihat tingkat kedekatan data dalam *cluster* yang sama (cohesion) serta tingkat pemisahan antar *cluster* yang berbeda (separation). Nilai yang semakin mendekati 1 menunjukkan bahwa *cluster* yang terbentuk semakin jelas dan terpisah dengan baik, sedangkan nilai yang mendekati 0 menunjukkan adanya tumpang tindih karakteristik antar *cluster*.

Pada penelitian ini, nilai *Silhouette Score* yang diperoleh belum menunjukkan pemisahan *cluster* yang sangat kuat. Namun demikian, hasil tersebut masih dapat diterima mengingat data pelanggan telekomunikasi memiliki karakteristik yang kompleks dan beragam. Banyak atribut pelanggan yang saling berkaitan, seperti lama berlangganan, biaya bulanan, jenis layanan, serta metode pembayaran, sehingga batas antar kelompok pelanggan tidak selalu dapat dipisahkan secara tegas. Kondisi ini menyebabkan beberapa pelanggan memiliki karakteristik yang berada di antara dua kelompok sehingga mempengaruhi nilai *Silhouette Score* yang dihasilkan.

Selain itu, tujuan utama penerapan *clustering* pada penelitian ini bukan untuk memperoleh pemisahan *cluster* yang sempurna, melainkan untuk menemukan pola dan segmentasi pelanggan yang dapat dimanfaatkan dalam mendukung pengambilan keputusan bisnis. Oleh karena itu, interpretasi hasil *clustering* tidak hanya didasarkan pada nilai evaluasi numerik, tetapi juga pada kemampuan *cluster* dalam menggambarkan karakteristik pelanggan yang berbeda dan mudah dipahami.

Hasil segmentasi yang diperoleh menunjukkan adanya perbedaan karakteristik yang cukup jelas antar kelompok pelanggan. Beberapa kelompok memiliki kecenderungan pelanggan dengan masa berlangganan yang lebih panjang dan tingkat loyalitas yang tinggi, sementara kelompok lainnya menunjukkan karakteristik pelanggan dengan risiko *Churn* yang lebih besar. Perbedaan karakteristik tersebut menunjukkan bahwa hasil *clustering* masih mampu memberikan informasi yang bernilai bagi perusahaan.

Dengan demikian, meskipun nilai *Silhouette Score* yang diperoleh belum tergolong tinggi, hasil segmentasi pelanggan tetap relevan dan bermanfaat untuk digunakan sebagai dasar dalam penyusunan strategi retensi pelanggan, program pemasaran yang lebih terarah, serta pengelompokan pelanggan berdasarkan tingkat loyalitas dan potensi risiko *Churn* yang dimiliki. Selain itu, hasil *clustering* ini dapat menjadi langkah awal bagi perusahaan untuk memahami perilaku pelanggan secara lebih mendalam dan mendukung proses pengambilan keputusan yang berbasis data.

G. Implikasi Bisnis

Penelitian ini bertujuan untuk memprediksi pelanggan yang berpotensi melakukan *Churn* serta mengelompokkan pelanggan berdasarkan karakteristik yang dimiliki. Berdasarkan hasil evaluasi model, algoritma XGBoost berhasil menghasilkan performa klasifikasi yang cukup baik dengan nilai *Accuracy* sebesar 76,65%, *Precision* sebesar 55,27%, *Recall* sebesar 63,10%, dan ROC-AUC sebesar 82,56%.

Nilai ROC-AUC yang berada di atas 80% menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan pelanggan *Churn* dan non-*Churn*. Hasil tersebut mengindikasikan bahwa model dapat digunakan sebagai alat bantu untuk mengidentifikasi pelanggan yang berpotensi meninggalkan layanan sebelum *Churn* benar-benar terjadi.

Dalam konteks bisnis telekomunikasi, kemampuan mengidentifikasi pelanggan berisiko *Churn* memiliki nilai yang sangat penting. Kehilangan pelanggan tidak hanya berdampak pada penurunan pendapatan perusahaan, tetapi juga meningkatkan biaya akuisisi pelanggan baru. Oleh karena itu, informasi yang dihasilkan model dapat dimanfaatkan sebagai dasar penyusunan strategi retensi pelanggan yang lebih efektif.

Berdasarkan hasil Feature Importance dan SHAP, ditemukan bahwa beberapa faktor utama yang mempengaruhi *Churn* pelanggan adalah metode pembayaran (Payment Method), jenis layanan internet (Internet Service), lama berlangganan (*Tenure*), biaya bulanan (Monthly Charges), serta jenis kontrak (*Contract*).

Temuan ini menunjukkan bahwa pelanggan yang menggunakan metode pembayaran *Electronic check* memiliki kecenderungan *Churn* yang lebih tinggi dibandingkan

pelanggan dengan metode pembayaran lainnya. Salah satu kemungkinan penyebabnya adalah proses pembayaran yang kurang praktis atau kurang nyaman dibandingkan metode pembayaran otomatis seperti kartu kredit atau transfer bank. Oleh karena itu, perusahaan dapat mendorong pelanggan untuk beralih ke metode pembayaran yang lebih mudah dan terintegrasi.

Selain itu, pelanggan dengan kontrak *Month-to-Month* juga menunjukkan tingkat *Churn* yang lebih tinggi dibandingkan pelanggan dengan kontrak tahunan maupun dua tahunan. Hal ini menunjukkan bahwa pelanggan yang tidak memiliki keterikatan kontrak jangka panjang lebih mudah berpindah ke penyedia layanan lain. Berdasarkan temuan tersebut, perusahaan dapat menawarkan program promosi atau diskon khusus untuk mendorong pelanggan berpindah ke kontrak jangka panjang.

Faktor lain yang memiliki pengaruh signifikan adalah lama berlangganan (*Tenure*). Pelanggan dengan masa berlangganan yang relatif singkat memiliki kecenderungan *Churn* yang lebih tinggi dibandingkan pelanggan yang telah lama menggunakan layanan perusahaan. Temuan ini menunjukkan pentingnya program *customer onboarding* pada bulan-bulan awal penggunaan layanan. Perusahaan perlu memastikan bahwa pelanggan baru memperoleh pengalaman penggunaan yang baik sehingga risiko *Churn* dapat ditekan sejak awal.

Hasil analisis juga menunjukkan bahwa pelanggan dengan biaya bulanan yang lebih tinggi memiliki kecenderungan *Churn* yang lebih besar. Kondisi tersebut dapat mengindikasikan adanya ketidaksesuaian antara biaya yang dibayarkan dengan manfaat yang dirasakan pelanggan. Oleh karena itu, perusahaan perlu memastikan bahwa kualitas layanan yang diberikan sebanding dengan biaya yang dibebankan kepada pelanggan.

Selain analisis prediksi *Churn*, penelitian ini juga menghasilkan segmentasi pelanggan menggunakan algoritma K-Means. Hasil *clustering* menunjukkan bahwa pelanggan dapat dikelompokkan ke dalam tiga segmen utama yang memiliki karakteristik berbeda. Segmentasi ini memberikan manfaat tambahan bagi perusahaan karena memungkinkan penerapan strategi yang lebih spesifik pada masing-masing kelompok pelanggan.

Pelanggan pada *cluster* yang memiliki risiko *Churn* tinggi dapat menjadi prioritas utama dalam program retensi. Sementara itu, pelanggan yang tergolong loyal dapat diberikan program penghargaan atau loyalitas untuk mempertahankan hubungan jangka panjang dengan perusahaan. Dengan demikian, hasil segmentasi tidak hanya memberikan informasi mengenai karakteristik pelanggan, tetapi juga mendukung proses pengambilan keputusan yang lebih terarah.

Secara keseluruhan, kombinasi antara model prediksi *Churn* menggunakan XGBoost dan segmentasi pelanggan menggunakan K-Means memberikan pendekatan yang lebih komprehensif dibandingkan hanya menggunakan salah satu metode saja. Model klasifikasi mampu mengidentifikasi pelanggan yang berpotensi *Churn*, sedangkan *clustering* membantu memahami karakteristik kelompok pelanggan secara lebih mendalam. Integrasi kedua pendekatan tersebut

dapat mendukung perusahaan dalam merancang strategi retensi pelanggan yang lebih efektif, efisien, dan berbasis *data*.


V. IMPLEMENTASI SISTEM

Aplikasi web yang dikembangkan pada penelitian ini berfungsi sebagai media untuk menampilkan hasil analisis *customer churn*, melihat ringkasan *dataset*, menjalankan prediksi terhadap *data* pelanggan baru, menampilkan visualisasi hasil analisis, serta menjelaskan metode yang digunakan dalam penelitian. Dengan demikian, model yang telah dibangun menjadi lebih mudah dipahami oleh pengguna, terutama bagi pengguna awam yang tidak berlatar belakang teknis.

Aplikasi dibangun menggunakan bahasa pemrograman Python dengan beberapa pustaka pendukung, seperti Streamlit untuk antarmuka web, Pandas untuk pengolahan *data*, Scikit-Learn untuk mendukung evaluasi model, Plotly dan Seaborn untuk visualisasi, serta Joblib untuk memuat model yang telah disimpan sebelumnya. Seluruh model dan hasil preprocessing yang digunakan di aplikasi berasal dari proses yang telah dilakukan pada Google Colab. Dalam implementasinya, aplikasi dijalankan secara lokal melalui browser dengan Streamlit. Hal ini memudahkan pengujian dan penyesuaian tampilan sebelum digunakan sebagai bahan presentasi atau demo.

A. Navigasi Aplikasi

Struktur navigasi aplikasi dibuat sederhana agar mudah digunakan oleh pengguna. Sidebar pada sisi kiri berisi lima menu utama, yaitu *Home*, *Dataset Overview*, *Prediction / Analysis*, *Visualization*, dan *About*.




Gbr. 13 Sidebar Aplikasi.

Menu *Home* digunakan sebagai halaman pembuka yang menjelaskan judul proyek, ringkasan penelitian, dan identitas pengembang. Menu *Dataset Overview* digunakan untuk menjelaskan karakteristik *dataset* yang dipakai. Menu *Prediction / Analysis* digunakan untuk melakukan prediksi *customer Churn* berdasarkan input pengguna sekaligus menampilkan evaluasi model. Menu *Visualization* digunakan

untuk menampilkan grafik-grafik pendukung agar hasil analisis lebih mudah dipahami. Menu *About* berisi penjelasan metode, informasi *dataset*, dan informasi proyek secara umum.

Secara umum, alur penggunaan aplikasi dimulai dari halaman *Home* yang menampilkan gambaran umum proyek. Setelah itu, pengguna dapat membuka halaman *Dataset Overview* untuk memahami *data* yang digunakan. Selanjutnya, pengguna dapat masuk ke halaman *Prediction / Analysis* untuk mencoba prediksi *customer churn* dengan mengisi form yang tersedia. Jika pengguna ingin melihat grafik tambahan, maka halaman *Visualization* dapat dibuka. Terakhir, halaman *About* digunakan untuk melihat ringkasan metode dan informasi penelitian.

B. Implementasi Halaman Home



Gbr. 14 Halaman Home.

Halaman *Home* merupakan halaman pertama yang ditampilkan ketika aplikasi dijalankan. Halaman ini berfungsi sebagai pengantar yang memberikan gambaran umum mengenai proyek yang dikembangkan. Pada halaman ini ditampilkan judul penelitian, deskripsi singkat proyek, informasi ringkasan hasil penelitian, serta identitas pengembang.

Deskripsi proyek menjelaskan bahwa penelitian berfokus pada prediksi *customer Churn* dan segmentasi pelanggan telekomunikasi menggunakan algoritma XGBoost dan K-Means. Informasi ini membantu pengguna memahami tujuan utama penelitian sebelum menggunakan fitur lainnya yang tersedia pada aplikasi.

Selain itu, halaman *Home* juga menampilkan beberapa informasi ringkas seperti jumlah *data* yang digunakan, nilai akurasi model, jumlah *cluster* yang terbentuk, dan persentase *Churn* pelanggan. Informasi tersebut disajikan dalam bentuk card sehingga mudah dipahami oleh pengguna. Penyajian ringkasan hasil penelitian pada halaman awal bertujuan untuk memberikan gambaran cepat mengenai performa model dan karakteristik *dataset* yang digunakan.


Identitas pengembang juga ditampilkan pada halaman ini sebagai informasi mengenai pembuat aplikasi. Dengan demikian, pengguna dapat mengetahui asal dan tujuan pengembangan sistem yang digunakan.

C. Implementasi Halaman Dataset Overview

Halaman *Dataset Overview* digunakan untuk menampilkan informasi terkait *dataset* yang digunakan dalam penelitian. Informasi yang ditampilkan meliputi jumlah *data*, jumlah

atribut, jumlah *data* kosong (missing value), serta persentase *Churn* pelanggan. Penyajian informasi ini bertujuan agar pengguna memperoleh pemahaman mengenai karakteristik *dataset* sebelum melihat hasil analisis yang lebih lanjut.

Selain informasi umum *dataset*, halaman ini juga menampilkan preview *data* sehingga pengguna dapat melihat contoh *data* pelanggan yang digunakan dalam proses penelitian. Preview *data* membantu pengguna memahami bentuk atribut yang tersedia serta jenis informasi yang terkandung dalam *dataset*.




Gbr. 15 Halaman *Dataset Overview*.

Halaman ini juga menampilkan statistik sederhana dari atribut numerik yang digunakan. Statistik yang ditampilkan meliputi nilai minimum, maksimum, rata-rata, median, dan standar deviasi. Informasi statistik ini membantu menjelaskan distribusi *data* secara umum.

Untuk memperjelas pemahaman terhadap *data*, halaman *Dataset Overview* dilengkapi dengan visualisasi distribusi *Churn* dan correlation heatmap. Visualisasi distribusi *Churn* digunakan untuk melihat perbandingan jumlah pelanggan *Churn* dan non-*Churn*. Sementara itu, correlation heatmap digunakan untuk melihat hubungan antar atribut numerik yang terdapat pada *dataset*.

Berdasarkan hasil visualisasi yang ditampilkan, terlihat bahwa jumlah pelanggan non-*Churn* lebih besar dibandingkan pelanggan *Churn*. Selain itu, terdapat hubungan yang cukup kuat antara atribut *TotalCharges* dan *tenure* yang menunjukkan bahwa pelanggan dengan masa berlangganan yang lebih lama cenderung memiliki total tagihan yang lebih besar.

D. Implementasi Halaman *Prediction / Analysis*



Gbr. 16 Halaman *Prediction / Analysis*

Halaman *Prediction / Analysis* merupakan bagian utama dari aplikasi karena digunakan untuk melakukan prediksi *customer Churn* berdasarkan *data* pelanggan yang dimasukkan oleh pengguna. Pada halaman ini tersedia *form* input yang berisi berbagai atribut pelanggan sesuai dengan fitur yang digunakan pada proses pelatihan model.

Pengguna dapat memasukkan informasi pelanggan seperti *gender*, *senior citizen*, *partner*, *dependents*, *tenure*, *internet service*, *Contract*, *payment method*, *monthly charges*, *total charges*, dan atribut lainnya. Setelah seluruh *data* diisi, pengguna dapat menekan tombol prediksi untuk menjalankan proses klasifikasi menggunakan model XGBoost yang telah dilatih sebelumnya.

Sistem kemudian melakukan preprocessing terhadap *data* input agar memiliki format yang sama dengan *data* yang digunakan pada proses pelatihan model. Selanjutnya model XGBoost menghasilkan prediksi berupa pelanggan *Churn* atau non-*Churn* beserta probabilitasnya.

Selain hasil prediksi, halaman ini juga menampilkan informasi performa model yang terdiri dari *accuracy*, *precision*, *recall*, dan ROC-AUC. Informasi tersebut bertujuan untuk memberikan gambaran mengenai kualitas model yang digunakan dalam aplikasi.

Berdasarkan implementasi yang dilakukan, sistem mampu menghasilkan prediksi secara cepat dan memberikan informasi yang mudah dipahami oleh pengguna. Hal ini menunjukkan bahwa model yang dibangun berhasil diintegrasikan dengan baik ke dalam aplikasi web.

E. Implementasi Halaman *Visualization*



Gbr. 17 Halaman *Visualization*.

Halaman *About* digunakan untuk menampilkan berbagai grafik pendukung yang dihasilkan dari proses analisis *data*. Visualisasi *data* berfungsi untuk membantu pengguna memahami pola-pola yang terdapat pada *dataset* secara lebih mudah dibandingkan hanya melihat tabel atau angka statistik.

Visualisasi yang ditampilkan pada aplikasi meliputi distribusi *Churn* pelanggan, hubungan antara *monthly charges* dan *Churn*, distribusi *tenure* pelanggan, feature importance model XGBoost, serta visualisasi *clustering* menggunakan metode K-Means.


Grafik distribusi *Churn* menunjukkan bahwa sebagian besar pelanggan masih berada pada kategori non-*Churn*. Visualisasi *monthly charges* terhadap *Churn* memperlihatkan adanya kecenderungan bahwa pelanggan dengan biaya bulanan

tertentu memiliki peluang *Churn* yang berbeda. Sementara itu, distribusi *tenure* menunjukkan bahwa pelanggan dengan masa berlangganan yang lebih panjang cenderung memiliki tingkat loyalitas yang lebih tinggi.

Hasil *clustering* divisualisasikan menggunakan *Principal Component Analysis* (PCA) sehingga tiga *cluster* yang terbentuk dapat terlihat secara lebih jelas dalam bentuk scatter plot dua dimensi. Visualisasi ini membantu pengguna memahami bagaimana pelanggan dikelompokkan berdasarkan kemiripan karakteristik yang dimiliki.

Dengan adanya berbagai visualisasi tersebut, hasil analisis menjadi lebih informatif dan mudah dipahami oleh pengguna yang tidak memiliki latar belakang teknis dalam bidang *data mining*.

F. Implementasi Halaman About



Gbr. 18 Halaman About.

Halaman *About* berfungsi sebagai dokumentasi singkat mengenai penelitian dan aplikasi yang dikembangkan. Pada halaman ini ditampilkan informasi mengenai *dataset* yang digunakan, metode yang diterapkan, serta informasi proyek.

Bagian *dataset* menjelaskan bahwa penelitian menggunakan *dataset* Telco Customer Churn yang terdiri dari 7.043 *data* pelanggan dengan 21 atribut utama sebelum proses preprocessing dilakukan. *Dataset* ini digunakan untuk mempelajari perilaku pelanggan telekomunikasi dan mengidentifikasi pelanggan yang berpotensi *Churn*.

Bagian metode menjelaskan algoritma yang digunakan dalam penelitian. XGBoost digunakan untuk melakukan klasifikasi *customer Churn*, K-Means digunakan untuk segmentasi pelanggan, SMOTE digunakan untuk mengatasi ketidakseimbangan kelas pada *data Churn*, sedangkan SHAP digunakan untuk membantu interpretasi model sehingga hasil prediksi dapat dijelaskan secara lebih mudah.

VI. KESIMPULAN

Penelitian ini berhasil menerapkan metode *data mining* untuk melakukan prediksi *customer Churn* dan segmentasi pelanggan pada *dataset* Telco Customer Churn menggunakan pendekatan CRISP-DM. *Dataset* yang digunakan terdiri dari 7.043 *data* pelanggan dengan berbagai atribut yang menggambarkan karakteristik pelanggan layanan telekomunikasi.

Pada tahap preprocessing dilakukan penanganan missing value, transformasi *data* kategorikal menggunakan encoding, standarisasi *data*, serta penyeimbangan kelas menggunakan metode SMOTE untuk mengatasi ketidakseimbangan *data*

Churn dan non-*Churn*. Tahapan tersebut bertujuan untuk meningkatkan kualitas *data* sebelum digunakan pada proses pemodelan.

Model klasifikasi dibangun menggunakan algoritma XGBoost untuk memprediksi kemungkinan pelanggan melakukan *Churn*. Berdasarkan hasil evaluasi, model menghasilkan nilai *Accuracy* sebesar 76,65%, *Precision* sebesar 55,27%, *Recall* sebesar 63,10%, dan ROC-AUC sebesar 82,56%. Nilai ROC-AUC yang cukup tinggi menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan pelanggan *Churn* dan non-*Churn*.

Selain klasifikasi, penelitian juga menerapkan algoritma K-Means untuk melakukan segmentasi pelanggan. Berdasarkan hasil evaluasi menggunakan Elbow Method dan *Silhouette Score*, diperoleh jumlah *cluster* optimal sebanyak tiga kelompok pelanggan. Hasil segmentasi menunjukkan bahwa pelanggan dapat dikelompokkan berdasarkan karakteristik penggunaan layanan, biaya bulanan, dan lama berlangganan sehingga dapat membantu perusahaan dalam menyusun strategi pemasaran dan retensi pelanggan yang lebih tepat sasaran.

Seluruh hasil analisis kemudian berhasil diimplementasikan ke dalam aplikasi web berbasis Streamlit yang terdiri dari halaman Home, *Dataset Overview*, Prediction/Analysis, Visualization, dan About. Aplikasi yang dikembangkan mampu menampilkan informasi *dataset*, visualisasi analisis, hasil prediksi *Churn*, serta dokumentasi metode yang digunakan sehingga memudahkan pengguna dalam memahami hasil penelitian secara interaktif.

Berdasarkan keseluruhan hasil penelitian, dapat disimpulkan bahwa kombinasi metode XGBoost dan K-Means mampu memberikan informasi yang bermanfaat dalam mengidentifikasi pelanggan yang berpotensi *Churn* serta memahami karakteristik kelompok pelanggan pada layanan telekomunikasi.

REFERENSI

- [1] M. Herawati, I. Mukhlash, & I. L. Wibowo. (2016). Prediksi Customer Churn Menggunakan Algoritma Fuzzy Iterative Dichotomiser 3. *Mathematics and Its Applications*, 13(1), 23-36.
- [2] E. C. Murphy, & M. A. Murphy. (2002). *Leading on the Edge of Chaos: The 10 Critical Elements for Success in Volatile Times*. USA: Prentice Hall Press.
- [3] H. K. Pambudi, P. G. A. Kusuma, F. Yulianti, & K. A. Julian. (2020). Prediksi Status Pengiriman Barang Menggunakan Metode Machine Learning. *Ilmiah Teknologi Informasi Terapan*, 6(2), 2686-0333.
- [4] C. Lukita, L. D. Bakti, U. Rusilowati, A. Sutarmanto, and U. Rahardja, "Predictive and Analytics Using Data Mining and Machine Learning for Customer Churn Prediction," *Journal of Applied Data Sciences*, vol. 4, no. 4, 2024, doi: 10.47738/jads.v4i4.131.
- [5] R. R. Adhitya, W. Witanti, and R. Yuniarti, "Perbandingan Metode CART dan Naïve Bayes untuk Klasifikasi Customer Churn," *Infotech Journal*, vol. 9, no. 2, pp. 307-318, 2023, doi: 10.31949/infotech.v9i2.5641.
- [6] M. A. Iskandar and U. Latifa, "Website Prediksi Customer Churn untuk Mempertahankan Pelanggan pada Perusahaan Telekomunikasi," *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 7, no. 2, 2023, doi: 10.36040/jati.v7i2.6639.
- [7] A. N. Khormarudin. (2016). Teknik data mining: Algoritma K-Means clustering. *J. Ilmu Komput.*
- [8] Shalev-Shwartz, S., & Ben-David, S. (2013). *Understanding machine learning: From theory to algorithms* (Vol. 9781107057). Cambridge University Press. DOI: 10.1017/CBO9781107298019.

- [9] X. Chen, Y. Wang, and H. Li. (2025). A Comprehensive Analysis of *Churn* Prediction in Telecommunications Using *Machine Learning*.
 - [10] J. M. John, O. Shobayo, and B. Ogunleye. (2024). An Exploration of *Clustering* Algorithms for *Customer* Segmentation in the UK Retail Market.
 - [11] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer. (2002). SMOTE: *Synthetic Minority Over-sampling Technique*. *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357.
 - [12] S. M. Lundberg and S.-I. Lee. (2017). A Unified Approach to Interpreting Model Predictions, in *Advances in Neural Information Processing Systems* (NeurIPS), pp. 4765–4774.
 - [13] T. Chen and C. Guestrin. (2016). XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, pp. 785–794.
- Link Gdrive Dataset
<https://drive.google.com/drive/folders/1OUpb3i4C7i7AZ2mJiXNIXUtbXTsGETdv?usp=sharing>
- Link Gdrive Kode Aplikasi
https://drive.google.com/drive/folders/1lGM2vFdOr3U7oiFSgVZYl8p_EfJiOpf4?usp=drive_link
- Link Gdrive Presentasi dan Demo Aplikasi
https://drive.google.com/drive/folders/19MDth38a9gxXx7DUKizq0mQeWq15luHB?usp=drive_link
- Link Gdrive Jupyter Notebook
https://drive.google.com/drive/folders/1GEFx0TBS_VSYfx0Fy9BMekcNbT9UVHzT?usp=drive_link
- Link Repository GitHub
<https://github.com/sierren/Projek-Akhir-Data-Mining-Telco-Customer-Churn.git>
- Link Gdrive Repository
https://drive.google.com/drive/folders/1XAfESSroh-4TldNxpC_Yf8uviKnovV?usp=drive_link